

实验报告：基于 MediaPipe Pose 与骨架序列 Transformer 的羽毛球击球动作识别

学生：沈嘉克 学号：2023101143

一、实验目标

1. 理解视频动作识别任务如何转化为骨架时间序列分类任务。
2. 掌握使用 MediaPipe Pose 从视频帧中提取人体 33 个关键点的方法。
3. 掌握将每段视频统一转换为固定长度骨架序列的方法，例如 [30, 132]。
4. 实现一个轻量级 Skeleton Transformer，用 Transformer Encoder 对动作序列分类。
5. 完成模型训练、测试集评估与单个视频样本推理。
6. 理解该方法在羽毛球商业化视频分析中的优势与局限。

二、数据集与标签

标签	英文类别	中文说明
0	forehand_drive	正手平抽 / 正手驱动球
1	forehand_lift	正手挑球
2	forehand_net_shot	正手网前球
3	forehand_clear	正手高远球
4	backhand_drive	反手平抽 / 反手驱动球
5	backhand_net_shot	反手网前球

本次运行共处理 836 个视频样本，训练集 668 个，测试集 168 个，训练测试划分比例为 8:2。

三、方法和模型结构

(一) 预处理

预处理阶段首先遍历 archive 数据集中 6 个类别文件夹，读取所有 .mp4、.avi、.mov 和 .mkv 视频。每个视频使用 OpenCV 打开并按时间均匀采样为 30 帧，然后将 BGR 图像转换为 RGB 图像送入 MediaPipe PoseLandmarker。

MediaPipe Pose 对每帧输出 33 个人体关键点，每个关键点包含 x、y、z 和 visibility 四个数值，因此每帧骨架特征维度为 $33 \times 4 = 132$ 。视频片段最终表示为 [30, 132] 的骨架序列。归一化时以左右髋部中心为原点，并优先使用肩宽作为尺度因子，以减少人物位置和尺度变化对分类的影响。

预处理完成后保存 X_train.npy、y_train.npy、X_test.npy、y_test.npy 和 label_map.json。本次输出中 X_train 的形状为 [668, 30, 132]，X_test 的形状为 [168, 30, 132]。

(二) 设计模型

模型采用 Skeleton Transformer Encoder 结构，整体流程如下：

输入骨架序列 X: [B, T, 132]

Linear Embedding: 132 → d_model

Position Embedding: 加入时间位置信息

Transformer Encoder × 2

Mean Pooling

MLP Classifier

输出 6 类羽毛球击球动作 logits

参数	取值	说明
input_dim	132	每帧骨架特征维度
target_frames	30	每段视频统一帧数
d_model	128	Transformer 主维度
nhead	4	多头注意力 head 数
num_layers	2	Transformer Encoder 层数
dim_feedforward	256	FFN 中间层维度
num_classes	6	Kaggle 数据集动作类别数
dropout	0.1	防止过拟合

(三) 训练与测试

训练阶段使用 PyTorch Dataset 与 DataLoader 组织骨架序列数据，损失函数为 CrossEntropyLoss，优化器为 Adam，学习率为 1e-3。每个 epoch 统计训练 loss、训练 accuracy、测试 loss 和测试 accuracy。测试阶段使用 model.eval() 和 torch.no_grad()，输出准确率、混淆矩阵和分类报告。

(四) 推理

推理阶段从测试集中选取一个样本，输入训练好的 Skeleton Transformer，模型输出 6 类 logits，随后通过 softmax 得到各类别概率，最终输出预测类别与置信度。

(五) 骨架可视化

为了观察 MediaPipe Pose 的关键点提取效果，实验额外选取视频片段进行骨架可视化，将检测到的关键点和身体连接边绘制到原视频帧上。

四、实验结果与问题分析


(1)

本次训练共运行 20 个 epoch，最后一轮训练准确率为 0.4341，最后一轮测试准确率为 0.3095。在最终测试集上的准确率为 0.3095。


从结果看，模型已经完成从骨架序列到动作类别的端到端分类流程，但准确率仍然有限。主要原因是羽毛球不同击球动作之间存在较强相似性，例如正手高远球、正手挑球和平抽动作都包含引拍、挥拍和收拍阶段；同时视频中人物尺寸较小、移动速度快，MediaPipe 关键点可能出现抖动或局部缺失。

混淆矩阵显示，部分类别之间存在明显混淆，说明单纯使用轻量 Pose 骨架坐标时，对细粒度击球动作的区分能力有限。后续可通过增加训练轮数、使用更高精度的 Pose 模型、加入关键点速度/角度特征、进行数据增强或结合球拍/球轨迹信息来提升识别效果。


training_loss.png



training_accuracy.png



confusion_matrix.png



(2) 单样本推理测试

单样本推理测试视频为 archive\forehand_clear\028.mp4。


真实类别: forehand_clear; 预测类别: backhand_drive; 置信度: 0.3816。从该样本可以看出, 模型虽然给出了最高概率类别, 但不同类别概率差距并不总是很大, 这也反映了细粒度动作识别任务的难度。

类别	logit	softmax 概率
forehand_drive	-0.0833	0.1426
forehand_lift	-1.0038	0.0568
forehand_net_shot	-0.7755	0.0714
forehand_clear	-1.0928	0.0520
backhand_drive	0.9009	0.3816
backhand_net_shot	0.6454	0.2956

(3) 骨架可视化

下图展示了 1-2 个视频片段的 MediaPipe 骨架可视化结果。可视化结果表明, 骨架序列能够保留人体挥拍姿态和身体运动趋势, 但也会受到遮挡、画面清晰度和姿态估计稳定性的影响。

骨架可视化示例 1



骨架可视化示例 2

